

# 高斯混合模型（GMM）推导及实现



永远在你...

垃圾知乎，疯狂推新建的视频小号，这么急着赚钱，为了办后事吗

关注他

384 人赞同了该文章

上一篇

永远在你身后：EM算法原理及推导  
271 赞同 · 23 评论 文章



讨论的EM算法的推导过程，本问结合EM算法来推导高斯混合模型的原理，并对其进行简单的实现

而它与K-means相比的优点是，K-means只能将每个样本划分为一个类，GMM可以给出一个样本对于所有类别的概率。GMM不仅仅可以用于聚类，还可以用于概率密度的估计，也可以用于生成新的样本

GMM是一个生成模型，它假设数据是从多个高斯分布中生成的，可以这样理解生成流程：有  $K$  个高斯分布，赋予每一个分布一个权重，每当生成一个数据时，就按权重的比例随机选择一个分布，然后按照该分布生成数据

那么根据数据进行反推，可以假定一个样本有一个潜在类别，而这个类别是无法观测到的，也就是隐变量，所以对于样本在给定参数  $\theta$  的条件下边际概率为：

$$P(x|\theta) = \sum_i^K P(x, z = C_i|\theta) = \sum_i^K P(z = C_i|\theta) P(x|\theta, z = C_i)$$

其中  $z = C_i$  表示样本属于某个类别， $P(z = C_i)$  也就是隐变量的概率分布

$z$	$C_1$	$C_2$	...	$C_K$
$P$	$p_1$	$p_2$	...	$p_K$

并且满足  $\sum_i^K p_i = 1$ ，且样本的条件概率分布服从于（多元）高斯分布，即  $x|\theta, z = C_i \sim \mathcal{N}(x|\mu_i, \Sigma_i)$ ：


$$\phi(x|\mu_i, \Sigma_i) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp\left(-\frac{(x - \mu_i)^T \Sigma_i^{-1} (x - \mu_i)}{2}\right)$$

上式假设样本含有  $d$  个属性。样本的边际概率为：

$$P(x|\theta) = \sum_i^K p_i \phi(x|\mu_i, \Sigma_i)$$

下面通过一个具体的栗子来对GMM进行推导，下图是三个二元高斯概率密度函数的图像

知乎

首发于  
技术部落联盟

这三个高斯的参数分别是，均值：

$$\mu_1 = \begin{bmatrix} 2.5 \\ 8 \end{bmatrix}, \mu_2 = \begin{bmatrix} 8 \\ 2.5 \end{bmatrix}, \mu_3 = \begin{bmatrix} 10 \\ 10 \end{bmatrix}$$

协方差矩阵：

$$\Sigma_1 = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \Sigma_2 = \begin{bmatrix} 3 & 2 \\ 1 & 2 \end{bmatrix}, \Sigma_3 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

下图是通过这三个高斯函数生成的数据

知乎

首发于  
技术部落联盟

现在，我们通过这些数据，使用GMM将这三个高斯的参数给估计出来

首先，明确变量与参数

$$X = (x_1, x_2, \dots, x_N)$$

$$Z = (z_1, z_2, \dots, z_N)$$

$$\theta = (p, \mu, \Sigma)$$

其中参数  $\theta$  包含隐变量  $Z$  的概率分布，各个高斯的均值与协方差矩阵：

$$p = (p_1, p_2, \dots, p_K)$$

$$\mu = (\mu_1, \mu_2, \dots, \mu_K)$$

$$\Sigma = (\Sigma_1, \Sigma_2, \dots, \Sigma_K)$$

然后是EM算法中的E步，写出  $Q$  函数：

知乎

首发于  
技术部落联盟

$$= \sum_Z \log P(X, Z | \theta) = \sum_Z \log \left( \prod_{i=1}^N P(x_i, z_i | \theta) \right)$$

因为每个样本的独立同分布的，所以对数似然可以写成：

$$\log P(X, Z | \theta) = \log \left( \prod_{i=1}^N P(x_i, z_i | \theta) \right) = \sum_{i=1}^N \log P(x_i, z_i | \theta)$$

以及  $Z$  的后验可以写成

$$P(Z | X, \theta^{(t)}) = \prod_{i=1}^N P(z_i | x_i, \theta^{(t)})$$

不过为了更加简洁，后验  $P(Z | X, \theta^{(t)})$  在下面的推导中先不展开

$$\begin{aligned} Q(\theta, \theta^{(t)}) &= \sum_Z \left[ \left( \sum_{i=1}^N \log P(x_i, z_i | \theta) \right) P(Z | X, \theta^{(t)}) \right] \\ &= \sum_Z \left[ \log P(x_1, z_1 | \theta) P(Z | X, \theta^{(t)}) + \dots + \log P(x_N, z_N | \theta) P(Z | X, \theta^{(t)}) \right] \\ &= \sum_Z \left( \log P(x_1, z_1 | \theta) P(Z | X, \theta^{(t)}) \right) + \dots + \sum_Z \left( \log P(x_N, z_N | \theta) P(Z | X, \theta^{(t)}) \right) \end{aligned}$$

可以看到， $Q$  函数被分出了  $N$  个相似的部分，我们将其中标红部分提出来化简

$$\begin{aligned} &\sum_Z \left( \log P(x_1, z_1 | \theta) P(Z | X, \theta^{(t)}) \right) \\ &= \sum_{z_1, z_2, \dots, z_N} \left( \log P(x_1, z_1 | \theta) \left( \prod_{i=1}^N P(z_i | x_i, \theta^{(t)}) \right) \right) \\ &= \sum_{z_1, z_2, \dots, z_N} \log P(x_1, z_1 | \theta) P(z_1 | x_1, \theta^{(t)}) \left( \prod_{i=2}^N P(z_i | x_i, \theta^{(t)}) \right) \\ &= \sum_{z_1} \sum_{z_2, \dots, z_N} \log P(x_1, z_1 | \theta) P(z_1 | x_1, \theta^{(t)}) \left( \prod_{i=2}^N P(z_i | x_i, \theta^{(t)}) \right) \\ &= \sum_{z_1} \log P(x_1, z_1 | \theta) P(z_1 | x_1, \theta^{(t)}) \sum_{z_2, \dots, z_N} \left( \prod_{i=2}^N P(z_i | x_i, \theta^{(t)}) \right) \end{aligned}$$

再把上式中蓝色部分提出来展开

知乎

首发于  
技术部落联盟

$$\begin{aligned}
&= \sum_{z_2} \sum_{z_3} \dots \sum_{z_N} \left( P(z_2|x_2, \theta^{(t)}) P(z_3|x_3, \theta^{(t)}) \dots P(z_N|x_N, \theta^{(t)}) \right) \\
&= \sum_{z_2} P(z_2|x_2, \theta^{(t)}) \sum_{z_3} P(z_3|x_3, \theta^{(t)}) \dots \sum_{z_N} P(z_N|x_N, \theta^{(t)})
\end{aligned}$$

可以看到,  $P(z_i|x_i, \theta^{(t)})$  是关于  $z_i$  的概率分布, 根据概率分布的性质有

$$\sum_{z_i} P(z_i|x_i, \theta^{(t)}) = 1$$

所以, 整个这一 (蓝色) 部分的值等于1, 代回前面的式子, 得到

$$\sum_Z \left( \log P(x_1, z_1|\theta) P(z_1|x_1, \theta^{(t)}) \right) = \sum_{z_1} \log P(x_1, z_1|\theta) P(z_1|x_1, \theta^{(t)})$$

同理, 可以得到

$$\begin{aligned}
&\sum_Z \left( \log P(x_2, z_2|\theta) P(z_2|x_2, \theta^{(t)}) \right) = \sum_{z_2} \log P(x_2, z_2|\theta) P(z_2|x_2, \theta^{(t)}) \\
&\vdots \\
&\sum_Z \left( \log P(x_N, z_N|\theta) P(z_N|x_N, \theta^{(t)}) \right) = \sum_{z_N} \log P(x_N, z_N|\theta) P(z_N|x_N, \theta^{(t)})
\end{aligned}$$

将这些化简的结果代回到  $Q$  函数, 可以得到

$$\begin{aligned}
&Q(\theta, \theta^{(t)}) \\
&= \sum_{z_1} \log P(x_1, z_1|\theta) P(z_1|x_1, \theta^{(t)}) + \dots + \sum_{z_N} \log P(x_N, z_N|\theta) P(z_N|x_N, \theta^{(t)}) \\
&= \sum_{i=1}^N \sum_{z_i} \log P(x_i, z_i|\theta) P(z_i|x_i, \theta^{(t)}) \\
&= \sum_{i=1}^N \sum_{k=1}^K \log P(x_i, z_i = C_j|\theta) P(z_i = C_j|x_i, \theta^{(t)}) \\
&= \sum_{i=1}^N \sum_{k=1}^K \log (p_k \phi(x_i|\mu_k, \Sigma_k)) P(z_i = C_k|x_i, \theta^{(t)}) \\
&= \sum_{i=1}^N \sum_{k=1}^K (\log p_k + \log \phi(x_i|\mu_k, \Sigma_k)) P(z_i = C_k|x_i, \theta^{(t)})
\end{aligned}$$

需要注意的是， $Q$  函数的两个参数中， $\theta^{(t)}$  是当前时刻的参数值，是已经确定的，该参数所对应的部分： $P(z_i = C_k | x_i, \theta^{(t)})$ ，是隐变量在当前参数下的后验概率，也是已经确定的，所以在后续的化简和求导中都可以当作常量处理

为了后面的推导更加简洁，先给该后验另取一个变量名  $\gamma$  作为表示：

$$\begin{aligned}\gamma_{ij} &= P(z_i = C_j | x_i, \theta^{(t)}) \\ &= \frac{P(x_i, z_i = C_j | \theta^{(t)})}{\sum_{k=1}^K P(x_i, z_i = C_k | \theta^{(t)})} \\ &= \frac{P(x_i | z_i = C_j, \theta^{(t)}) P(z_i = C_j | \theta^{(t)})}{\sum_{k=1}^K P(x_i | z_i = C_k, \theta^{(t)}) P(z_i = C_k | \theta^{(t)})} \\ &= \frac{p_j \phi(x_i | \mu_j, \Sigma_j)}{\sum_{k=1}^K p_k \phi(x_i | \mu_k, \Sigma_k)}\end{aligned}$$

下面，就是EM算法中的M步，根据确定的  $Q$  函数求下一时刻的参数，首先是  $Z$  的概率分布：

$$\begin{aligned}p^{(t+1)} &= \arg \max_p \sum_{i=1}^N \sum_{k=1}^K (\log p_k + \log \phi(x_i | \mu_k, \Sigma_k)) \gamma_{ik} \\ &= \arg \max_p \sum_{i=1}^N \sum_{k=1}^K \log p_k \gamma_{ik}\end{aligned}$$

不过，这里不能直接求导，因为概率分布有一个约束： $\sum_i p_i = 1$ 。所以，通过拉格朗日乘数法来消除该约束。构造一个拉格朗日函数：

$$L(p, \lambda) = \sum_{i=1}^N \sum_{k=1}^K \log p_k \gamma_{ik} + \lambda \left( \sum_i p_i - 1 \right)$$

对该函数求导

$$\frac{\partial L(p_k, \lambda)}{\partial p_j} = \sum_{i=1}^N \frac{1}{p_j} \gamma_{ij} + \lambda$$

令偏导为0，并且两边同时乘上  $p_j$ ，得到：

N

知乎

首发于  
技术部落联盟

$$\begin{aligned}\frac{\partial L(p_k, \lambda)}{\partial p_1} &\Rightarrow \sum_{i=1}^N \gamma_{i1} = -\lambda p_1 \\ &\vdots \\ \frac{\partial L(p_k, \lambda)}{\partial p_K} &\Rightarrow \sum_{i=1}^N \gamma_{iK} = -\lambda p_K\end{aligned}$$

将所有分量的结果相加，得到：

$$\sum_{j=1}^K \sum_{i=1}^N \gamma_{ij} = \sum_{j=1}^K -\lambda p_j$$

首先，利用之前的约束条件： $\sum_i p_i = 1$ ，所以上式右边结果为  $-\lambda$ 。又因为  $\gamma_{ij}$  也是一个概率分布，所以有： $\sum_j \gamma_{ij} = 1$ ，最终得到：

$$\lambda = -N$$

代入 (1.1) 式，得到：

$$p_j^{(t+1)} = \frac{1}{N} \sum_{i=1}^N \gamma_{ij}$$

然后是各个高斯的均值：

$$\begin{aligned}\mu^{(t+1)} &= \arg \max_{\mu} \sum_{i=1}^N \sum_{k=1}^K (\log p_k + \log \phi(x_i | \mu_k, \Sigma_k)) \gamma_{ik} \\ &= \arg \max_{\mu} \sum_{i=1}^N \sum_{k=1}^K \log \phi(x_i | \mu_k, \Sigma_k) \gamma_{ik} \\ &= \arg \max_{\mu} \sum_{i=1}^N \sum_{k=1}^K \left( \log \frac{1}{(2\pi)^{\frac{d}{2}}} - \frac{1}{2} \log |\Sigma_k| - \frac{(x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k)}{2} \right) \gamma_{ik} \\ &= \arg \max_{\mu} \sum_{i=1}^N \sum_{k=1}^K \left( -\frac{(x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k)}{2} \right) \gamma_{ik}\end{aligned}$$

这里没有约束条件，直接对上式求导

已赞同 384

26 条评论

分享

喜欢

收藏

申请转载

...



知乎

首发于  
技术部落联盟

$$\begin{aligned}
&= \frac{\partial}{\partial \mu_j} \left( \sum_{i=1}^N \left( -\frac{(x_i - \mu_j)^T \Sigma_j^{-1} (x_i - \mu_j)}{2} \right) \gamma_{ij} \right) \\
&= \sum_{i=1}^N \left( -\frac{1}{2} \frac{\partial}{\partial \mu_j} \left( (x_i - \mu_j)^T \Sigma_j^{-1} (x_i - \mu_j) \right) \right) \gamma_{ij} \\
&= \sum_{i=1}^N \Sigma_j^{-1} (x_i - \mu_j) \gamma_{ij} \\
&= \sum_{i=1}^N \Sigma_j^{-1} x_i \gamma_{ij} - \sum_{i=1}^N \Sigma_j^{-1} \mu_j \gamma_{ij}
\end{aligned}$$

令偏导为0，并且两端同时乘上  $\Sigma_j^2$ ：

$$\sum_{i=1}^N x_i \gamma_{ij} = \mu_j \sum_{i=1}^N \gamma_{ij}$$

最后得到：

$$\mu_j^{(t+1)} = \frac{\sum_{i=1}^N x_i \gamma_{ij}}{\sum_{i=1}^N \gamma_{ij}}$$

最后，就是协方差矩阵的更新了，首先化简  $Q$  函数

$$\begin{aligned}
\Sigma^{(t+1)} &= \arg \max_{\Sigma} \sum_{i=1}^N \sum_{k=1}^K \left( \log \frac{1}{(2\pi)^{\frac{d}{2}}} - \frac{1}{2} \log |\Sigma_k| - \frac{(x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k)}{2} \right) \gamma_{ik} \\
&= \arg \min_{\Sigma} \sum_{i=1}^N \sum_{k=1}^K \left( \log |\Sigma_k| + (x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k) \right) \gamma_{ik}
\end{aligned}$$

这里，先把特征值的求导公式贴出来，对于一个矩阵  $A$ ，有：

$$\begin{aligned}
\frac{\partial |A|}{\partial A} &= |A| A^{-1} \\
\frac{\partial \log |A|}{\partial A} &= A^{-1}
\end{aligned}$$

接着，求  $Q$  函数关于协方差的偏导：

$$\begin{aligned}
&= \sum_{i=1}^N \frac{\partial}{\partial \Sigma_j} \left( \log |\Sigma_j| + (\mathbf{x}_i - \mu_j)^T \Sigma_j^{-1} (\mathbf{x}_i - \mu_j) \right) \gamma_{ij} \\
&= \sum_{i=1}^N \left( \Sigma_j^{-1} - (\mathbf{x}_i - \mu_j) (\mathbf{x}_i - \mu_j)^T \Sigma_j^{-2} \right) \gamma_{ij}
\end{aligned}$$

下面对上式中标红部分的求导过程进行展开，因为  $(\mathbf{x}_i - \mu_j)^T \Sigma_j^{-1} (\mathbf{x}_i - \mu_j)$  的结果是一个标量，也可以视作是一个  $1 \times 1$  的矩阵，所以它就迹就等于它自身。又因为

$$() = ()$$

所以，变换得到

$$\begin{aligned}
(\mathbf{x}_i - \mu_j)^T \Sigma_j^{-1} (\mathbf{x}_i - \mu_j) &= \text{tr} \left( (\mathbf{x}_i - \mu_j)^T \Sigma_j^{-1} (\mathbf{x}_i - \mu_j) \right) \\
&= \text{tr} \left( \Sigma_j^{-1} (\mathbf{x}_i - \mu_j) (\mathbf{x}_i - \mu_j)^T \right)
\end{aligned}$$

同样，矩阵的迹求导公式为：

$$\frac{\partial \text{tr}(AB)}{\partial A} = B^T$$

所以

$$\begin{aligned}
\frac{\partial \text{tr} \left( \Sigma_j^{-1} (\mathbf{x}_i - \mu_j) (\mathbf{x}_i - \mu_j)^T \right)}{\partial \Sigma_j} &= (\mathbf{x}_i - \mu_j) (\mathbf{x}_i - \mu_j)^T \frac{\partial \Sigma_j^{-1}}{\partial \Sigma_j} \\
&= -(\mathbf{x}_i - \mu_j) (\mathbf{x}_i - \mu_j)^T \Sigma_j^{-2}
\end{aligned}$$

接着，令偏导为0，并且两端同时乘上  $\Sigma_j^2$ ：

$$\begin{aligned}
\sum_{i=1}^N \left( \Sigma_j - (\mathbf{x}_i - \mu_j) (\mathbf{x}_i - \mu_j)^T \right) \gamma_{ij} &= 0 \\
\Sigma_j \sum_{i=1}^N \gamma_{ij} &= \sum_{i=1}^N (\mathbf{x}_i - \mu_j) (\mathbf{x}_i - \mu_j)^T \gamma_{ij}
\end{aligned}$$

最后得到：

$$\Sigma_j = \frac{1}{\sum_{i=1}^N \gamma_{ij}} \sum_{i=1}^N (\mathbf{x}_i - \mu_j) (\mathbf{x}_i - \mu_j)^T \gamma_{ij}$$

以上，全部的公式已经推导完毕，现在整理一下

$$\gamma_{ij} = \frac{p_j \phi(x_i | \mu_j, \Sigma_j)}{\sum_{k=1}^K p_k \phi(x_i | \mu_k, \Sigma_k)}$$

$$p_j^{(t+1)} = \frac{1}{N} \sum_{i=1}^N \gamma_{ij}$$

$$\mu_j^{(t+1)} = \frac{\sum_{i=1}^N x_i \gamma_{ij}}{\sum_{i=1}^N \gamma_{ij}}$$

$$\mu_j^{(t+1)} = \frac{\sum_{i=1}^N x_i \gamma_{ij}}{\sum_{i=1}^N \gamma_{ij}}$$

最后的最后，根据以上公式，写一个简单的实现

```
import numpy as np
from scipy import stats

class GMM(object):
    def __init__(self, k: int, d: int):
        """
        k: K值
        d: 样本属性的数量
        """
        self.K = k
        # 初始化参数
        self.p = np.random.rand(k)
        self.p = self.p / self.p.sum() # 保证所有p_k的和为1
        self.means = np.random.rand(k, d)
        self.covs = np.empty((k, d, d))
        for i in range(k): # 随机生成协方差矩阵，必须是半正定矩阵
            self.covs[i] = np.eye(d) * np.random.rand(1) * k

    def fit(self, data: np.ndarray):
        """
        data: 数据矩阵，每一行是一个样本，shape = (N, d)
        """
        for _ in range(100):
            density = np.empty((len(data), self.K))
            for i in range(self.K):
```

知乎

首发于  
技术部落联盟

```

posterior = density * self.p
posterior = posterior / posterior.sum(axis=1, keepdims=True)
# 计算下一时刻的参数值
p_hat = posterior.sum(axis=0)
mean_hat = np.tensordot(posterior, data, axes=[0, 0])
# 计算协方差
cov_hat = np.empty(self.covs.shape)
for i in range(self.K):
    tmp = data - self.means[i]
    cov_hat[i] = np.dot(tmp.T*posterior[:,i], tmp) / p_hat[i]
# 更新参数
self.covs = cov_hat
self.means = mean_hat / p_hat.reshape(-1,1)
self.p = p_hat / len(data)

print(self.p)
print(self.means)
print(self.covs)

```

随机生成了2000个样本，迭代100次后的结果如下：

```

p = np.array([0.3, 0.6, 0.1])
means = np.array([
    [2.5,8],
    [8,2.5],
    [10,10]
])
covs = np.array([
    [[2,1],[1,2]],
    [[3,2],[1,2]],
    [[2,0],[0,2]]
])

# 隐变量概率分布
[0.29775162 0.59836025 0.10388813]
# 均值
[[ 2.48575471  8.22122078]
 [ 7.95854299  2.46035662]
 [10.03840073  9.95829754]]
# 协方差

```

知乎

首发于  
技术部落联盟
$$\begin{bmatrix} 1.42297665 & 2.21976053 \end{bmatrix}$$
$$\begin{bmatrix} 2.07091948 & -0.03055896 \\ -0.03055896 & 2.07287524 \end{bmatrix}$$

可以看到，基本上已经收敛的差不多了

编辑于 2019-10-07 14:22

机器学习    自然语言处理    人工智能

## 文章被以下专栏收录



### 技术部落联盟

涉及容器、大数据、人工智能、物联网等领域



### 一个大学生的日常笔记

你能找到的最通俗易懂的大学生数学与编程知识分享

## 推荐阅读

MACHINE  
LEARNING



高斯混合模型(GMM)的两种详解及简化

磊磊

Gaussian Mixture Model

高斯混合模型

机器学习-白板推导系列(十一)  
高斯混合模型GMM (Gaussi...

磊磊、

已赞同 384

26 条评论

分享


喜欢


收藏

申请转载

...

写下你的评论...



 枫雪镜夜 2020-12-04

一定是看了B站的机器学习下白板推导



 4

 lucky 2020-03-26

cj是不是应该改成ck?

 1

 水库浪子 回复 lucky 2020-11-29


我觉得要改，应该是写混了

 赞


 六毛吧 2019-12-10

如果我是多维数据怎么办

 1

 学弱獠  2019-11-21



这篇文章可以投到我的专栏内嘛

 1


 永远在你身后 (作者) 回复 学弱獠  2019-11-22

恩，注明来源即可

 1

 学弱獠  回复 永远在你身后 (作者) 2019-11-22

投稿需要宁帮忙投进来，我好像才能接收🤔

 赞

展开其他 2 条回复

 信自门下遛狗 2020-12-17

这篇推导简直牛逼

👍 赞



海川

11-06

从群里特地前来拜读

👍 赞



ngc111

2020-06-01

您好可以转载一下吗，会标注好来源

👍 赞



聃珠

2019-12-09

棒！学到很多

👍 赞



ECHO

08-10

赞一个，白板推导没有期望和方差的EM，这篇文章都补齐了

👍 赞



Haha

07-12

请问多维数据比如1000个变量，如何根据gmm聚类？

👍 赞



angus zou

03-11



👍 赞



三弦

03-04

博主你好 我想问一下gmm需要对训练数据进行标准化吗？

👍 赞



我是狮子啊

01-15

为啥 $P(x|\theta)$  称之为 边际概率？写成这个形式不应该是条件概率么？

👍 赞

已赞同 384

26 条评论

分享

喜欢

收藏

申请转载

...



我是狮子啊 回复 Reloaded

05-24

应该是笔误

赞



念念不忘必有回响

01-13

GMM的参数初始化, 可以用kmeans来做吗

赞



Nights

2020-10-15

你好你的2000个数据是如何生成的, 是按照GMM给定的参数生成的么

赞



喜欢一只雪梨 回复 Nights

04-02

请问你现在有这个的初始数据吗

赞



慕橙cC

2020-10-07

你好, 先给你点赞! 太强啦! 另外想问下是否可以证明k-means是GMM在簇先验服从均匀分布、服从相等球形协方差矩阵时的特例呢?

赞



罗凡

2020-08-07

碰到好多次, 后面写r还有写 diag的, 这是什么意思

赞